

DS52

Fondements de la Science des Données

Version Mathématique Complète

Contenu de ce document

Ce document développe les **fondements mathématiques** sous-jacents à chaque méthode du kit DS52. Pour chaque algorithme, modèle ou technique, les formules sont présentées, dérivées et expliquées dans leur contexte.

Domaines couverts : Statistique bayésienne · Optimisation convexe · Algèbre linéaire · Théorie de l'information · Apprentissage statistique · Réseaux de neurones · Méthodes à noyaux · Processus gaussiens

Table des matières

1	Fondements Statistiques et Probabilistes	3
1.1	Espace de probabilité et variables aléatoires	3
1.1.1	Lois de référence	3
1.2	Théorème de Bayes	3
1.2.1	Maximum de Vraisemblance (MLE)	4
1.2.2	Maximum A Posteriori (MAP)	4
1.3	Compromis Biais-Variance	4
2	Prétraitement des Données	4
2.1	Normalisation et Standardisation	4
2.1.1	StandardScaler	4
2.1.2	MinMaxScaler	5
2.1.3	RobustScaler	5
2.2	Détection des Valeurs Aberrantes	5
2.2.1	Méthode IQR	5
2.2.2	Z-score	5
2.2.3	Isolation Forest	5
2.3	Réduction de Dimensionnalité	6
2.3.1	Analyse en Composantes Principales (PCA)	6
2.3.2	Analyse Discriminante Linéaire (LDA)	6
3	Régularisation	7
3.1	Ridge (L2)	7
3.2	LASSO (L1)	7
3.3	Elastic Net	8
4	Modèles de Classification	8
4.1	Régression Logistique	8
4.1.1	Modèle	8
4.1.2	Estimation par MLE	8
4.2	Support Vector Machine (SVM)	8
4.2.1	SVM linéaire — marge dure	9
4.2.2	SVM à marge souple (soft margin)	9
4.2.3	Noyaux (Kernel trick)	9
4.3	K-Nearest Neighbors (KNN)	10
4.4	Arbres de Décision (CART)	10
4.5	Random Forest	10
4.5.1	Bagging (Bootstrap Aggregating)	11
4.6	Gradient Boosting	11
4.7	Naive Bayes	12
5	Métriques d'Évaluation	12
5.1	Classification	12
5.1.1	Matrice de confusion et métriques de base	12
5.1.2	Courbe ROC et AUC	12
5.1.3	Log-Loss (entropie croisée)	13
5.1.4	Coefficient de Corrélation de Matthews (MCC)	13
5.2	Régression	13

6	Modèles de Régression	13
6.1	Régression Linéaire (MCO)	14
6.2	Régression Polynomiale	14
6.3	Processus Gaussiens (GPR)	14
7	Deep Learning	15
7.1	Perceptron et Réseau de Neurones	15
7.1.1	Fonctions d'activation	15
7.2	Rétropropagation du Gradient	15
7.3	Optimiseurs	15
7.4	Fonctions de Perte	16
7.5	Réseaux Convolutifs (CNN)	16
7.6	LSTM (Long Short-Term Memory)	17
8	Validation et Sélection de Modèle	17
8.1	Validation Croisée	17
8.2	Hyperparamètres et Optimisation Bayésienne	18
9	Explicabilité (XAI)	18
9.1	Valeurs de Shapley	18
9.2	LIME	19
9.3	Partial Dependence Plot (PDP)	19
10	Clustering et Détection d'Anomalies	19
10.1	K -Means	19
10.2	Modèles de Mélange Gaussien (GMM)	20
11	Séries Temporelles	20
11.1	Stationnarité et Test ADF	20
11.2	ARIMA	20
11.3	Prophet (Modèle additif)	21
12	Traitement du Langage Naturel (NLP)	21
12.1	TF-IDF	21
12.2	Word2Vec	21
13	Récapitulatif des Formules Clés	21

1. Fondements Statistiques et Probabilistes

1.1. Espace de probabilité et variables aléatoires

Définition — Variable aléatoire

Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace de probabilité. Une **variable aléatoire** $X : \Omega \rightarrow \mathbb{R}$ est une fonction mesurable. Sa **loi** est caractérisée par sa fonction de répartition :

$$F_X(x) = \mathbb{P}(X \leq x), \quad x \in \mathbb{R}$$

Pour une v.a. *continue*, la densité f_X vérifie $F_X(x) = \int_{-\infty}^x f_X(t) dt$ et $\int_{-\infty}^{+\infty} f_X(t) dt = 1$.

Formule — Espérance, Variance, Covariance

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x f_X(x) dx \quad (1)$$

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 \quad (2)$$

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] \quad (3)$$

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}} \in [-1, 1] \quad (\text{corrélation de Pearson}) \quad (4)$$

1.1.1. Loïs de référence

Loi normale $\mathcal{N}(\mu, \sigma^2)$:

$$f(x; \mu, \sigma^2) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

Loi de Bernoulli $\mathcal{B}(p)$: $\mathbb{P}(X = 1) = p$, $\mathbb{P}(X = 0) = 1 - p$, $\mathbb{E}[X] = p$, $\text{Var}(X) = p(1 - p)$.

Loi multinomiale avec classes $c \in \{1, \dots, K\}$:

$$\mathbb{P}(Y = c \mid \mathbf{x}) = \frac{e^{\mathbf{w}_c^\top \mathbf{x}}}{\sum_{k=1}^K e^{\mathbf{w}_k^\top \mathbf{x}}}$$

1.2. Théorème de Bayes

Théorème — Bayes

Pour deux événements A et B avec $\mathbb{P}(B) > 0$:

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(B \mid A) \mathbb{P}(A)}{\mathbb{P}(B)}$$

Dans le cadre de l'inférence statistique, avec θ les paramètres et $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$ les données :

$$\underbrace{p(\theta \mid \mathcal{D})}_{\text{posterior}} = \frac{\underbrace{p(\mathcal{D} \mid \theta)}_{\text{vraisemblance}} \cdot \underbrace{p(\theta)}_{\text{prior}}}{\underbrace{p(\mathcal{D})}_{\text{evidence}}}$$

L'evidence $p(\mathcal{D}) = \int p(\mathcal{D} \mid \theta) p(\theta) d\theta$ est souvent intractable, mais n'intervient pas dans MAP/MLE.

1.2.1. Maximum de Vraisemblance (MLE)

Formule — MLE

On cherche les paramètres $\hat{\theta}$ qui maximisent la probabilité des données observées :

$$\hat{\theta}_{\text{MLE}} = \underset{\theta}{\operatorname{argmax}} \mathcal{L}(\theta; \mathcal{D}) = \underset{\theta}{\operatorname{argmax}} \prod_{i=1}^n p(y_i | \mathbf{x}_i, \theta)$$

Par monotonie du logarithme, on maximise la **log-vraisemblance** :

$$\hat{\theta}_{\text{MLE}} = \underset{\theta}{\operatorname{argmax}} \ell(\theta) = \sum_{i=1}^n \log p(y_i | \mathbf{x}_i, \theta)$$

La régression logistique utilise MLE pour estimer β (voir §4.1).

1.2.2. Maximum A Posteriori (MAP)

Formule — MAP

$$\hat{\theta}_{\text{MAP}} = \underset{\theta}{\operatorname{argmax}} \log p(\theta | \mathcal{D}) = \underset{\theta}{\operatorname{argmax}} [\ell(\theta) + \log p(\theta)]$$

Avec un prior gaussien $p(\theta) = \mathcal{N}(0, 1/\lambda I)$, on obtient :

$$\hat{\theta}_{\text{MAP}} = \underset{\theta}{\operatorname{argmax}} \left[\ell(\theta) - \frac{\lambda}{2} \|\theta\|^2 \right] \Leftrightarrow \text{régularisation L2 (Ridge)}$$

1.3. Compromis Biais-Variance

Formule — Décomposition Biais-Variance

Pour un estimateur $\hat{f}$ entraîné sur un dataset $\mathcal{D}$ et une perte quadratique :

$$\mathbb{E}_{\mathcal{D}, \varepsilon} [(y - \hat{f}(\mathbf{x}))^2] = \underbrace{\left(\mathbb{E}_{\mathcal{D}}[\hat{f}(\mathbf{x})] - f(\mathbf{x}) \right)^2}_{\text{Bias}^2(\hat{f})} + \underbrace{\mathbb{E}_{\mathcal{D}} \left[\left(\hat{f}(\mathbf{x}) - \mathbb{E}_{\mathcal{D}}[\hat{f}(\mathbf{x})] \right)^2 \right]}_{\text{Var}(\hat{f})} + \underbrace{\sigma_{\varepsilon}^2}_{\text{bruit irréductible}}$$

- Bias² élevé $\Rightarrow$ le modèle est trop simple (underfitting).
- Var élevée $\Rightarrow$ le modèle est trop sensible aux données (overfitting).
- $\sigma_{\varepsilon}^2 = \text{Var}(\varepsilon)$ est incompressible.

2. Prétraitement des Données

2.1. Normalisation et Standardisation

2.1.1. StandardScaler

Formule — Standardisation Z-score

Pour une variable X à n observations $\{x_1, \dots, x_n\}$:

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \hat{\sigma} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \hat{\mu})^2}$$

$$z_i = \frac{x_i - \hat{\mu}}{\hat{\sigma}} \Rightarrow \mathbb{E}[Z] = 0, \text{Var}(Z) = 1$$

Attention : $\hat{\mu}$ et $\hat{\sigma}$ sont calculés *uniquement* sur $\mathcal{D}_{\text{train}}$, puis appliqués à $\mathcal{D}_{\text{test}}$ pour éviter le data leakage.

2.1.2. MinMaxScaler

Formule — Normalisation Min-Max

$$x_i^* = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}} \in [0, 1]$$

Sensible aux valeurs aberrantes car $x_{\min}$ et $x_{\max}$ dépendent des extrêmes.

2.1.3. RobustScaler

Formule — Mise à l'échelle robuste

Utilise la *médiane* $\tilde{x}$ et l'écart interquartile $\text{IQR} = Q_3 - Q_1$:

$$x_i^* = \frac{x_i - \tilde{x}}{\text{IQR}}$$

Robuste aux outliers car les quantiles sont peu affectés par les valeurs extrêmes.

2.2. Détection des Valeurs Aberrantes

2.2.1. Méthode IQR

Formule — Règle des clôtures de Tukey

$$\text{borne_inf} = Q_1 - 1.5 \cdot \text{IQR}, \quad \text{borne_sup} = Q_3 + 1.5 \cdot \text{IQR}$$

Toute observation $x_i \notin [\text{borne_inf}, \text{borne_sup}]$ est candidate outlier. Le facteur 1.5 est conventionnel ; 3.0 correspond aux outliers extrêmes.

2.2.2. Z-score

Formule — Z-score standardisé

$$z_i = \frac{x_i - \hat{\mu}}{\hat{\sigma}}$$

Si $|z_i| > 3$, l'observation est considérée comme outlier (règle empirique : moins de 0.3% des données d'une $\mathcal{N}(0, 1)$ dépassent $|z| = 3$).

2.2.3. Isolation Forest

Formule — Score d'anomalie

Un arbre d'isolation isole une observation $\mathbf{x}$ en $h(\mathbf{x})$ coupures aléatoires. Le score d'anomalie est :

$$s(\mathbf{x}, n) = 2^{-\frac{\mathbb{E}[h(\mathbf{x})]}{c(n)}}, \quad c(n) = 2H_{n-1} - \frac{2(n-1)}{n}$$

où $H_k = \sum_{i=1}^k 1/i$ est le k -ième nombre harmonique et $c(n)$ est la profondeur moyenne d'un arbre binaire de recherche à n nœuds. Un score $s \rightarrow 1$ indique une anomalie ; $s \rightarrow 0.5$ une observation normale.

2.3. Réduction de Dimensionnalité

2.3.1. Analyse en Composantes Principales (PCA)

Formule — PCA — Optimisation

Étant donné $\mathbf{X} \in \mathbb{R}^{n \times p}$ (centrée), la PCA cherche les directions $\mathbf{w}_k \in \mathbb{R}^p$ qui maximisent la variance projetée :

$$\mathbf{w}_k = \underset{\|\mathbf{w}\|=1, \mathbf{w} \perp \mathbf{w}_1, \dots, \mathbf{w}_{k-1}}{\operatorname{argmax}} \operatorname{Var}(\mathbf{X}\mathbf{w}) = \underset{\|\mathbf{w}\|=1}{\operatorname{argmax}} \mathbf{w}^\top \boldsymbol{\Sigma} \mathbf{w}$$

où $\boldsymbol{\Sigma} = \frac{1}{n-1} \mathbf{X}^\top \mathbf{X}$ est la matrice de covariance empirique.

Théorème — Décomposition spectrale

$\boldsymbol{\Sigma}$ est symétrique définie positive, donc diagonalisable :

$$\boldsymbol{\Sigma} = \mathbf{V} \boldsymbol{\Lambda} \mathbf{V}^\top, \quad \boldsymbol{\Lambda} = \operatorname{diag}(\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0)$$

Les composantes principales sont les colonnes $\mathbf{v}_k$ de $\mathbf{V}$ (vecteurs propres). La proportion de variance expliquée par la k -ième composante est :

$$\rho_k = \frac{\lambda_k}{\sum_{j=1}^p \lambda_j}$$

Formule — SVD et PCA

Via la décomposition en valeurs singulières $\mathbf{X} = \mathbf{U} \mathbf{S} \mathbf{V}^\top$:

$$\boldsymbol{\Sigma} = \frac{\mathbf{X}^\top \mathbf{X}}{n-1} = \frac{\mathbf{V} \mathbf{S}^2 \mathbf{V}^\top}{n-1} \Rightarrow \lambda_k = \frac{s_k^2}{n-1}$$

La projection sur $K < p$ composantes est :

$$\tilde{\mathbf{X}} = \mathbf{X} \mathbf{V}_K \in \mathbb{R}^{n \times K}$$

2.3.2. Analyse Discriminante Linéaire (LDA)

Formule — Critère de Fisher

La LDA maximise le ratio *variance inter-classes* / *variance intra-classes* :

$$J(\mathbf{w}) = \frac{\mathbf{w}^\top \mathbf{S}_B \mathbf{w}}{\mathbf{w}^\top \mathbf{S}_W \mathbf{w}}$$

où la matrice de dispersion inter-classes est

$$\mathbf{S}_B = \sum_{c=1}^C n_c (\boldsymbol{\mu}_c - \boldsymbol{\mu})(\boldsymbol{\mu}_c - \boldsymbol{\mu})^\top$$

et la matrice de dispersion intra-classes est

$$\mathbf{S}_W = \sum_{c=1}^C \sum_{i \in \mathcal{C}_c} (\mathbf{x}_i - \boldsymbol{\mu}_c)(\mathbf{x}_i - \boldsymbol{\mu}_c)^\top$$

La solution est donnée par le problème aux valeurs propres généralisé : $\mathbf{S}_B \mathbf{w} = \lambda \mathbf{S}_W \mathbf{w}$, soit $\mathbf{S}_W^{-1} \mathbf{S}_B \mathbf{w} = \lambda \mathbf{w}$.

3. Régularisation

3.1. Ridge (L2)

Formule — Régularisation Ridge

Le problème d'optimisation est :

$$\hat{\boldsymbol{\beta}}_{\text{Ridge}} = \underset{\boldsymbol{\beta}}{\operatorname{argmin}} \left[\underbrace{\|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2}_{\text{RSS}} + \lambda \underbrace{\|\boldsymbol{\beta}\|_2^2}_{\text{L2}} \right] = \underset{\boldsymbol{\beta}}{\operatorname{argmin}} \sum_{i=1}^n (y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2 + \lambda \sum_{j=1}^p \beta_j^2$$

La solution analytique est :

$$\hat{\boldsymbol{\beta}}_{\text{Ridge}} = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}$$

Interprétation bayésienne : $\hat{\boldsymbol{\beta}}_{\text{Ridge}} = \hat{\boldsymbol{\theta}}_{\text{MAP}}$ avec prior $\boldsymbol{\beta} \sim \mathcal{N}(\mathbf{0}, \sigma^2 / \lambda \mathbf{I})$.

3.2. LASSO (L1)

Formule — Régularisation LASSO

$$\hat{\boldsymbol{\beta}}_{\text{LASSO}} = \underset{\boldsymbol{\beta}}{\operatorname{argmin}} \left[\|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2 + \lambda \|\boldsymbol{\beta}\|_1 \right] = \underset{\boldsymbol{\beta}}{\operatorname{argmin}} \sum_{i=1}^n (y_i - \mathbf{x}_i^\top \boldsymbol{\beta})^2 + \lambda \sum_{j=1}^p |\beta_j|$$

Pas de solution fermée (non différentiable en 0). Solveur ISTA/LARS. La pénalité L1 produit des solutions **parcimonieuses** : $\hat{\beta}_j = \operatorname{sign}(\tilde{\beta}_j) \max(|\tilde{\beta}_j| - \lambda/2, 0)$ (opérateur de seuillage doux / *soft-thresholding*).

3.3. Elastic Net

Formule — Elastic Net

Combine L1 et L2 avec un coefficient $\alpha \in [0, 1]$:

$$\hat{\beta}_{\text{EN}} = \underset{\beta}{\operatorname{argmin}} \left[\|\mathbf{y} - \mathbf{X}\beta\|^2 + \lambda \left(\alpha \|\beta\|_1 + (1 - \alpha) \|\beta\|_2^2 \right) \right]$$

$\alpha = 1 \Rightarrow \text{LASSO}$; $\alpha = 0 \Rightarrow \text{Ridge}$.

4. Modèles de Classification

4.1. Régression Logistique

4.1.1. Modèle

Formule — Fonction logistique (sigmoïde)

$$\sigma(z) = \frac{1}{1 + e^{-z}} \in (0, 1), \quad \frac{d\sigma}{dz} = \sigma(z)(1 - \sigma(z))$$

Le modèle prédit la probabilité de la classe positive :

$$P(Y = 1 \mid \mathbf{x}; \beta) = \sigma(\beta^\top \mathbf{x}) = \frac{1}{1 + \exp(-\beta_0 - \beta_1 x_1 - \cdots - \beta_p x_p)}$$

Définition — Log-odds (logit)

$$\log \left(\frac{P(Y = 1 \mid \mathbf{x})}{P(Y = 0 \mid \mathbf{x})} \right) = \beta^\top \mathbf{x}$$

β_j est le log du rapport de cotes (log-odds ratio) associé à x_j ; e^{β_j} est l'**odds ratio** : une augmentation unitaire de x_j multiplie l'odds par e^{β_j} .

4.1.2. Estimation par MLE

Formule — Fonction de coût — Cross-entropy binaire

Pour n observations i.i.d., la log-vraisemblance négative (à minimiser) est :

$$\mathcal{J}(\beta) = -\ell(\beta) = -\sum_{i=1}^n [y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)]$$

où $\hat{p}_i = \sigma(\beta^\top \mathbf{x}_i)$. Le gradient est :

$$\nabla_{\beta} \mathcal{J}(\beta) = \mathbf{X}^\top (\hat{\mathbf{p}} - \mathbf{y}) = \sum_{i=1}^n (\hat{p}_i - y_i) \mathbf{x}_i$$

La matrice Hessienne $\mathbf{H} = \mathbf{X}^\top \mathbf{W} \mathbf{X}$ avec $\mathbf{W} = \text{diag}(\hat{p}_i(1 - \hat{p}_i))$ est semi-définie positive : $\mathcal{J}$ est **convexe** — convergence garantie vers le minimum global.

4.2. Support Vector Machine (SVM)

4.2.1. SVM linéaire — marge dure

Définition — Hyperplan séparateur

Un hyperplan $\mathcal{H} = \{\mathbf{x} : \mathbf{w}^\top \mathbf{x} + b = 0\}$ sépare les classes si $y_i(\mathbf{w}^\top \mathbf{x}_i + b) > 0$ pour tout i . La **marge fonctionnelle** de $(\mathbf{x}_i, y_i)$ est $\gamma_i = y_i(\mathbf{w}^\top \mathbf{x}_i + b)$.

Formule — Problème primal (marge dure)

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \quad \text{s.c.} \quad y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad i = 1, \dots, n$$

La marge géométrique est $\frac{2}{\|\mathbf{w}\|}$. Maximiser la marge $\equiv$ minimiser $\|\mathbf{w}\|^2$.

4.2.2. SVM à marge souple (soft margin)

Formule — Problème primal avec variables d'écart

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \quad \text{s.c.} \quad y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0$$

$C > 0$ contrôle le compromis marge/erreurs. $C \rightarrow \infty$: marge dure.

Formule — Problème dual (méthode des multiplicateurs de Lagrange)

On forme le Lagrangien :

$$\mathcal{L} = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_i \xi_i - \sum_i \alpha_i [y_i(\mathbf{w}^\top \mathbf{x}_i + b) - 1 + \xi_i] - \sum_i \mu_i \xi_i$$

Les conditions KKT ($\partial \mathcal{L} / \partial \mathbf{w} = 0$, etc.) donnent le dual :

$$\max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle \quad \text{s.c.} \quad 0 \leq \alpha_i \leq C, \quad \sum_i \alpha_i y_i = 0$$

La solution prend la forme $\mathbf{w}^* = \sum_i \alpha_i y_i \mathbf{x}_i$ (combinaison des **vecteurs de support** : $\alpha_i > 0$).

4.2.3. Noyaux (Kernel trick)

Définition — Fonction noyau

Un noyau $k : \mathbb{R}^p \times \mathbb{R}^p \rightarrow \mathbb{R}$ est une fonction symétrique définie positive telle qu'il existe $\phi : \mathbb{R}^p \rightarrow \mathcal{H}$ (espace de Hilbert) vérifiant $k(\mathbf{x}, \mathbf{x}') = \langle \phi(\mathbf{x}), \phi(\mathbf{x}') \rangle_{\mathcal{H}}$.

Formule — Noyaux courants

$$\text{Linéaire :} \quad k(\mathbf{x}, \mathbf{x}') = \mathbf{x}^\top \mathbf{x}'$$

$$\text{RBF (Gaussien) :} \quad k(\mathbf{x}, \mathbf{x}') = \exp\left(-\frac{\|\mathbf{x} - \mathbf{x}'\|^2}{2\ell^2}\right)$$

$$\text{Polynomial :} \quad k(\mathbf{x}, \mathbf{x}') = (\mathbf{x}^\top \mathbf{x}' + c)^d$$

Le *kernel trick* substitue $\langle \mathbf{x}_i, \mathbf{x}_j \rangle$ par $k(\mathbf{x}_i, \mathbf{x}_j)$ dans le dual, sans calculer ϕ explicitement.

4.3. K-Nearest Neighbors (KNN)

Formule — Distance de Minkowski

$$d_p(\mathbf{a}, \mathbf{b}) = \left(\sum_{j=1}^p |a_j - b_j|^p \right)^{1/p}$$

$p = 1$: Manhattan ; $p = 2$: Euclidienne ; $p \rightarrow \infty$: Tchebychev.

Formule — Règle de décision KNN

$$\hat{y} = \underset{c}{\operatorname{argmax}} \sum_{i \in \mathcal{N}_k(\mathbf{x})} \mathbf{1}[y_i = c]$$

où $\mathcal{N}_k(\mathbf{x})$ est l'ensemble des k plus proches voisins de $\mathbf{x}$. En régression : $\hat{y} = \frac{1}{k} \sum_{i \in \mathcal{N}_k(\mathbf{x})} y_i$.

Théorème — Taux d'erreur asymptotique de Cover et Hart (1967)

Quand $n \rightarrow \infty$ et $k/n \rightarrow 0$, le taux d'erreur du 1-NN vérifie :

$$P^* \leq R_{1\text{-NN}} \leq 2P^* \left(1 - \frac{C-1}{C} P^* \right)$$

où P^* est le taux de Bayes (minimum théorique) et C le nombre de classes.

4.4. Arbres de Décision (CART)

Définition — Impureté de Gini

Pour un nœud t avec K classes et proportions $\hat{p}_{tk}$:

$$\text{Gini}(t) = 1 - \sum_{k=1}^K \hat{p}_{tk}^2 = \sum_{k \neq k'} \hat{p}_{tk} \hat{p}_{tk'}$$

$\text{Gini}(t) = 0$: nœud pur ; maximum atteint pour une distribution uniforme.

Définition — Entropie de Shannon

$$H(t) = - \sum_{k=1}^K \hat{p}_{tk} \log_2 \hat{p}_{tk}$$

avec convention $0 \log 0 = 0$. Mesure l'incertitude du nœud.

Formule — Gain d'information

Pour un split s divisant t en t_L (n_L obs.) et t_R (n_R obs.) :

$$\Delta I(s, t) = I(t) - \frac{n_L}{n} I(t_L) - \frac{n_R}{n} I(t_R)$$

CART choisit $(s^*, t^*) = \operatorname{argmax}_{s, t} \Delta I(s, t)$. En régression, $I(t) = \text{MSE}(t) = \frac{1}{n_t} \sum_{i \in t} (y_i - \bar{y}_t)^2$.

4.5. Random Forest

4.5.1. Bagging (Bootstrap Aggregating)

Formule — Bagging

On construit B arbres $\hat{f}^{(b)}$ sur des échantillons bootstrap $\mathcal{D}^{(b)}$ (tirage avec remise de n observations) :

$$\hat{f}_{\text{bag}}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{(b)}(\mathbf{x})$$

Réduction de variance : si les B modèles ont variance σ^2 et corrélation ρ , alors $\text{Var}(\hat{f}_{\text{bag}}) = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2$. Quand $B \rightarrow \infty$, la variance résiduelle est $\rho\sigma^2$ (le terme corrélé).

Formule — Random Forest — double randomisation

À chaque split d'un arbre, seul un sous-ensemble aléatoire de $m \approx \sqrt{p}$ features (classification) ou $m \approx p/3$ (régression) est considéré, réduisant la corrélation ρ entre arbres :

$$\hat{f}_{\text{RF}}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{(b)}(\mathbf{x})$$

La variance théorique est $\text{Var}(\hat{f}_{\text{RF}}) = \rho_m \sigma^2 + \frac{1-\rho_m}{B} \sigma^2$ avec $\rho_m < \rho_{\text{bagging}}$.

4.6. Gradient Boosting

Formule — Boosting — principe général

On construit des apprenants h_b séquentiellement pour minimiser :

$$\hat{F}^{(B)}(\mathbf{x}) = \sum_{b=0}^B \eta h_b(\mathbf{x}), \quad \eta \in (0, 1]$$

À chaque étape b , h_b est entraîné sur les **pseudo-résidus** (gradient négatif) :

$$r_i^{(b)} = - \left[\frac{\partial \mathcal{L}(y_i, F(\mathbf{x}_i))}{\partial F(\mathbf{x}_i)} \right]_{F=F^{(b-1)}}$$

Formule — XGBoost — objectif régularisé

$$\mathcal{J}^{(b)} = \sum_{i=1}^n \mathcal{L}(y_i, \hat{y}_i^{(b-1)} + f_b(\mathbf{x}_i)) + \Omega(f_b)$$

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$$

où T est le nombre de feuilles, w_j les poids des feuilles. Développement de Taylor au second ordre :

$$\mathcal{J}^{(b)} \approx \sum_{i=1}^n \left[g_i f_b(\mathbf{x}_i) + \frac{1}{2} h_i f_b(\mathbf{x}_i)^2 \right] + \Omega(f_b)$$

avec $g_i = \partial_{\hat{y}} \mathcal{L}(y_i, \hat{y})$ (gradient) et $h_i = \partial_{\hat{y}}^2 \mathcal{L}(y_i, \hat{y})$ (hessien).

4.7. Naive Bayes

Formule — Classifieur Naive Bayes

Sous hypothèse d'indépendance conditionnelle des features :

$$\hat{y} = \underset{c}{\operatorname{argmax}} P(Y = c) \prod_{j=1}^p P(X_j = x_j | Y = c)$$

En pratique, on travaille en log-espace :

$$\hat{y} = \underset{c}{\operatorname{argmax}} \left[\log P(Y = c) + \sum_{j=1}^p \log P(X_j = x_j | Y = c) \right]$$

Gaussian NB : $P(X_j = x_j | Y = c) = \frac{1}{\sigma_{jc}\sqrt{2\pi}} \exp\left(-\frac{(x_j - \mu_{jc})^2}{2\sigma_{jc}^2}\right)$ où μ_{jc}, σ_{jc}^2 sont estimés par MLE sur les données de classe c .

5. Métriques d'Évaluation

5.1. Classification

5.1.1. Matrice de confusion et métriques de base

Formule — Métriques issues de la matrice de confusion

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (5)$$

$$\text{Precision} = \frac{TP}{TP + FP} \quad (\text{valeur prédictive positive}) \quad (6)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (\text{sensibilité, taux de vrais positifs}) \quad (7)$$

$$\text{Spécificité} = \frac{TN}{TN + FP} \quad (\text{taux de vrais négatifs}) \quad (8)$$

$$F_1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2TP}{2TP + FP + FN} \quad (9)$$

$$F_\beta = (1 + \beta^2) \frac{\text{Precision} \cdot \text{Recall}}{\beta^2 \text{Precision} + \text{Recall}} \quad (10)$$

F_β avec $\beta > 1$ pénalise davantage les faux négatifs (ex. détection médicale).

5.1.2. Courbe ROC et AUC

Définition — ROC — Receiver Operating Characteristic

La courbe ROC trace le Taux de Vrais Positifs (TVP = Recall) en fonction du Taux de Faux Positifs (TFP = $FP/(FP + TN)$) en faisant varier le seuil $\tau \in [0, 1]$.

$$\text{AUC} = \int_0^1 \text{TVP}(\text{TFP}) d(\text{TFP})$$

Théorème — Interprétation probabiliste de l'AUC

$$\text{AUC} = \mathbb{P}(\hat{p}(y = 1 | \mathbf{x}^+) > \hat{p}(y = 1 | \mathbf{x}^-))$$

où $\mathbf{x}^+$ est un exemple positif et $\mathbf{x}^-$ un exemple négatif tirés aléatoirement. $\text{AUC} = 0.5$: classifieur aléatoire ; $\text{AUC} = 1$: classifieur parfait.

5.1.3. Log-Loss (entropie croisée)**Formule — Log-Loss**

$$\mathcal{L}_{\log} = -\frac{1}{n} \sum_{i=1}^n [y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)]$$

Pénalise les prédictions confiantes et erronées : $y_i = 1, \hat{p}_i \rightarrow 0 \Rightarrow \mathcal{L}_{\log} \rightarrow +\infty$.

5.1.4. Coefficient de Corrélation de Matthews (MCC)**Formule — MCC**

$$\text{MCC} = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}} \in [-1, 1]$$

Propriété : $\text{MCC} = 0$ pour un classifieur aléatoire, indépendamment du déséquilibre.

5.2. Régression**Formule — Métriques de régression**

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (11)$$

$$\text{RMSE} = \sqrt{\text{MSE}} \quad (\text{même unité que } y) \quad (12)$$

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (13)$$

$$R^2 = 1 - \frac{\text{SS}_{\text{res}}}{\text{SS}_{\text{tot}}} = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2} \in (-\infty, 1] \quad (14)$$

$$R_{\text{adj}}^2 = 1 - (1 - R^2) \frac{n - 1}{n - p - 1} \quad (15)$$

$$\text{MAPE} = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| (\%) \quad (16)$$

6. Modèles de Régression

6.1. Régression Linéaire (MCO)

Formule — Moindres Carrés Ordinaires

$$\hat{\beta}_{\text{OLS}} = \underset{\beta}{\operatorname{argmin}} \|\mathbf{y} - \mathbf{X}\beta\|^2 = \underset{\beta}{\operatorname{argmin}} \sum_{i=1}^n (y_i - \mathbf{x}_i^\top \beta)^2$$

Solution analytique (si $\mathbf{X}^\top \mathbf{X}$ est inversible) :

$$\hat{\beta}_{\text{OLS}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

Théorème — Gauss-Markov

Sous les hypothèses : (1) $\mathbb{E}[\varepsilon] = \mathbf{0}$, (2) $\operatorname{Var}(\varepsilon) = \sigma^2 \mathbf{I}$, (3) $\mathbf{X}$ fixée de rang plein — l'estimateur MCO est le **BLUE** (*Best Linear Unbiased Estimator*) :

$$\operatorname{Var}(\hat{\beta}_{\text{OLS}}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}$$

Estimation de σ^2 : $\hat{\sigma}^2 = \frac{\|\mathbf{y} - \mathbf{X}\hat{\beta}\|^2}{n-p-1}$ (sans biais).

6.2. Régression Polynomiale

Formule — Extension polynomiale

On remplace $\mathbf{x} \in \mathbb{R}^p$ par $\phi(\mathbf{x}) = [1, x_1, \dots, x_p, x_1^2, \dots, x_p^2, x_1 x_2, \dots]$ et on applique OLS :

$$\hat{y} = \hat{\beta}^\top \phi(\mathbf{x})$$

Le nombre de features explose : $\binom{p+d}{d}$ termes pour le degré d .

6.3. Processus Gaussiens (GPR)

Définition — Processus gaussien

Un processus gaussien $f \sim \mathcal{GP}(m, k)$ est une distribution sur des fonctions telle que, pour tout ensemble fini de points $\{\mathbf{x}_1, \dots, \mathbf{x}_n\}$:

$$\begin{pmatrix} f(\mathbf{x}_1) \\ \vdots \\ f(\mathbf{x}_n) \end{pmatrix} \sim \mathcal{N}(\mathbf{m}, \mathbf{K})$$

où $m_i = m(\mathbf{x}_i)$ et $K_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$ (matrice de Gram).

Formule — Prédiction GPR

Avec n observations $(\mathbf{X}, \mathbf{y})$ et bruit gaussien $\varepsilon \sim \mathcal{N}(0, \sigma_n^2)$:

$$f_* \mid \mathbf{X}, \mathbf{y}, \mathbf{x}_* \sim \mathcal{N}(\bar{f}_*, \operatorname{Var}(f_*))$$

$$\bar{f}_* = \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I})^{-1} \mathbf{y}$$

$$\operatorname{Var}(f_*) = k(\mathbf{x}_*, \mathbf{x}_*) - \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I})^{-1} \mathbf{k}_*$$

où $\mathbf{k}_* = [k(\mathbf{x}_*, \mathbf{x}_1), \dots, k(\mathbf{x}_*, \mathbf{x}_n)]^\top$. Complexité computationnelle : $\mathcal{O}(n^3)$ (inversion de $\mathbf{K}$).

7. Deep Learning

7.1. Perceptron et Réseau de Neurones

Formule — Couche affine + activation

Pour une couche ℓ avec n_ℓ neurones, poids $\mathbf{W}^{(\ell)} \in \mathbb{R}^{n_\ell \times n_{\ell-1}}$ et biais $\mathbf{b}^{(\ell)} \in \mathbb{R}^{n_\ell}$:

$$\mathbf{z}^{(\ell)} = \mathbf{W}^{(\ell)} \mathbf{a}^{(\ell-1)} + \mathbf{b}^{(\ell)}, \quad \mathbf{a}^{(\ell)} = \phi(\mathbf{z}^{(\ell)})$$

Le réseau complet : $\hat{\mathbf{y}} = f_\theta(\mathbf{x}) = \mathbf{a}^{(L)}$.

7.1.1. Fonctions d'activation

Formule — Fonctions d'activation

$$\text{Sigmoid : } \sigma(z) = \frac{1}{1 + e^{-z}}, \quad \sigma'(z) = \sigma(z)(1 - \sigma(z))$$

$$\text{Tanh : } \tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}, \quad \tanh'(z) = 1 - \tanh^2(z)$$

$$\text{ReLU : } \text{ReLU}(z) = \max(0, z), \quad \frac{d}{dz} \text{ReLU}(z) = \mathbf{1}[z > 0]$$

$$\text{Leaky ReLU : } f(z) = \max(\alpha z, z), \quad \alpha \ll 1$$

$$\text{Softmax : } \text{softmax}(\mathbf{z})_k = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}, \quad \sum_k \text{softmax}(\mathbf{z})_k = 1$$

$$\text{GELU : } \text{GELU}(z) = z \Phi(z) \approx 0.5z \left(1 + \tanh \left(\sqrt{\frac{2}{\pi}} (z + 0.044715z^3) \right) \right)$$

où Φ est la CDF de la loi normale standard.

7.2. Rétropropagation du Gradient

Formule — Règle de la chaîne — Backpropagation

Pour la perte $\mathcal{J}$, on calcule les gradients par récurrence arrière. **Signal d'erreur (delta)** de la couche ℓ :

$$\delta^{(\ell)} = \frac{\partial \mathcal{J}}{\partial \mathbf{z}^{(\ell)}} = \left(\mathbf{W}^{(\ell+1)\top} \delta^{(\ell+1)} \right) \odot \phi'(\mathbf{z}^{(\ell)})$$

Gradients des paramètres :

$$\frac{\partial \mathcal{J}}{\partial \mathbf{W}^{(\ell)}} = \delta^{(\ell)} \mathbf{a}^{(\ell-1)\top}, \quad \frac{\partial \mathcal{J}}{\partial \mathbf{b}^{(\ell)}} = \delta^{(\ell)}$$

Condition initiale (sortie) : $\delta^{(L)} = \nabla_{\mathbf{a}^{(L)}} \mathcal{J} \odot \phi'(\mathbf{z}^{(L)})$.

7.3. Optimiseurs

Formule — Descente de gradient stochastique (SGD)

Mise à jour à chaque mini-batch $\mathcal{B}$ de taille B :

$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t - \eta \underbrace{\frac{1}{B} \sum_{i \in \mathcal{B}} \nabla_{\boldsymbol{\theta}} \mathcal{L}_i(\boldsymbol{\theta}_t)}_{\hat{\mathbf{g}}_t}$$

Formule — Adam (Adaptive Moment Estimation)

Maintient des estimations des moments de premier et second ordre :

$$\mathbf{m}_t = \beta_1 \mathbf{m}_{t-1} + (1 - \beta_1) \hat{\mathbf{g}}_t \quad (\text{1er moment — momentum})$$

$$\mathbf{v}_t = \beta_2 \mathbf{v}_{t-1} + (1 - \beta_2) \hat{\mathbf{g}}_t^{\odot 2} \quad (\text{2nd moment — variance})$$

Correction du biais (initialisation à 0) :

$$\hat{\mathbf{m}}_t = \frac{\mathbf{m}_t}{1 - \beta_1^t}, \quad \hat{\mathbf{v}}_t = \frac{\mathbf{v}_t}{1 - \beta_2^t}$$

Mise à jour :

$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t - \frac{\eta}{\sqrt{\hat{\mathbf{v}}_t} + \epsilon} \odot \hat{\mathbf{m}}_t$$

Valeurs par défaut : $\beta_1 = 0.9$, $\beta_2 = 0.999$, $\epsilon = 10^{-8}$.

Formule — RMSprop

$$\mathbf{v}_t = \gamma \mathbf{v}_{t-1} + (1 - \gamma) \hat{\mathbf{g}}_t^{\odot 2}, \quad \boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t - \frac{\eta}{\sqrt{\mathbf{v}_t} + \epsilon} \odot \hat{\mathbf{g}}_t$$

7.4. Fonctions de Perte**Formule — Cross-entropy binaire (BCE)**

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{n} \sum_{i=1}^n [y_i \log \sigma(z_i) + (1 - y_i) \log(1 - \sigma(z_i))]$$

Formule — Cross-entropy catégorielle

Pour K classes avec vecteur one-hot $\mathbf{y}_i$:

$$\mathcal{L}_{\text{CE}} = -\frac{1}{n} \sum_{i=1}^n \sum_{k=1}^K y_{ik} \log \hat{p}_{ik} = -\frac{1}{n} \sum_{i=1}^n \log \hat{p}_{i, c_i}$$

Formule — Perte de Huber (robuste aux outliers)

$$\mathcal{L}_{\delta}(y, \hat{y}) = \begin{cases} \frac{1}{2}(y - \hat{y})^2 & \text{si } |y - \hat{y}| \leq \delta \\ \delta(|y - \hat{y}| - \frac{\delta}{2}) & \text{sinon} \end{cases}$$

7.5. Réseaux Convolutifs (CNN)

Formule — Opération de convolution 2D

Pour un filtre $\mathbf{K} \in \mathbb{R}^{k_h \times k_w}$ et une entrée $\mathbf{X}$:

$$(\mathbf{X} \star \mathbf{K})_{ij} = \sum_{m=0}^{k_h-1} \sum_{n=0}^{k_w-1} X_{i+m, j+n} \cdot K_{m,n}$$

Dimension de la carte de sortie avec *padding* p et *stride* s :

$$\text{dim_sortie} = \left\lfloor \frac{\text{dim_entrée} + 2p - k}{s} \right\rfloor + 1$$

Nombre de paramètres par filtre : $k_h \times k_w \times C_{\text{in}} + 1$ (biais).

Formule — Batch Normalization

Pour un mini-batch $\mathcal{B} = \{x_1, \dots, x_B\}$:

$$\mu_{\mathcal{B}} = \frac{1}{B} \sum_{i=1}^B x_i, \quad \sigma_{\mathcal{B}}^2 = \frac{1}{B} \sum_{i=1}^B (x_i - \mu_{\mathcal{B}})^2$$

$$\hat{x}_i = \frac{x_i - \mu_{\mathcal{B}}}{\sqrt{\sigma_{\mathcal{B}}^2 + \epsilon}}, \quad y_i = \gamma \hat{x}_i + \beta \quad (\gamma, \beta \text{ apprenables})$$

Réduit le *covariate shift* interne ; accélère l'entraînement.

7.6. LSTM (Long Short-Term Memory)**Formule — Équations LSTM**

Pour l'entrée $\mathbf{x}_t$ et l'état caché précédent $\mathbf{h}_{t-1}$:

$$\mathbf{f}_t = \sigma(\mathbf{W}_f[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f) \quad (\text{porte oubli}) \quad (17)$$

$$\mathbf{i}_t = \sigma(\mathbf{W}_i[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i) \quad (\text{porte entrée}) \quad (18)$$

$$\tilde{\mathbf{c}}_t = \tanh(\mathbf{W}_c[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_c) \quad (\text{cellule candidate}) \quad (19)$$

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t \quad (\text{état cellule}) \quad (20)$$

$$\mathbf{o}_t = \sigma(\mathbf{W}_o[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o) \quad (\text{porte sortie}) \quad (21)$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t) \quad (\text{état caché}) \quad (22)$$

Les portes $\sigma(\cdot) \in (0, 1)$ contrôlent le flux d'information. La porte d'oubli $\mathbf{f}_t$ résout le problème du *vanishing gradient* des RNN simples.

8. Validation et Sélection de Modèle**8.1. Validation Croisée****Formule — K-Fold Cross-Validation**

On partitionne $\mathcal{D}$ en K sous-ensembles disjoints $\mathcal{D}_1, \dots, \mathcal{D}_K$. Pour chaque pli k :

$$\hat{\theta}_k = \mathcal{A}(\mathcal{D} \setminus \mathcal{D}_k), \quad \hat{R}_k = \frac{1}{|\mathcal{D}_k|} \sum_{i \in \mathcal{D}_k} \mathcal{L}(y_i, f_{\hat{\theta}_k}(\mathbf{x}_i))$$

Estimateur du risque généralisé :

$$\hat{R}_{CV} = \frac{1}{K} \sum_{k=1}^K \hat{R}_k, \quad \widehat{\text{se}}(\hat{R}_{CV}) = \sqrt{\frac{1}{K(K-1)} \sum_{k=1}^K (\hat{R}_k - \hat{R}_{CV})^2}$$

8.2. Hyperparamètres et Optimisation Bayésienne

Formule — Optimisation bayésienne (Gaussian Process)

On modélise $f : \Lambda \rightarrow \mathbb{R}$ (mapping hyperparamètres $\rightarrow$ score) par un GP :

$$f \sim \mathcal{GP}(\mu_0, k_0)$$

À chaque itération t , on évalue f au point qui maximise la **fonction d'acquisition** (ex. Expected Improvement) :

$$\text{EI}(\lambda) = \mathbb{E}_f[\max(f(\lambda) - f^*, 0)] = (f(\lambda)^* - \mu_t(\lambda))\Phi(Z) + \sigma_t(\lambda)\phi(Z)$$

$$Z = \frac{f^* - \mu_t(\lambda)}{\sigma_t(\lambda)}$$

où $f^* = \max_{i < t} f(\lambda_i)$, Φ la CDF et ϕ la PDF normales standard.

9. Explicabilité (XAI)

9.1. Valeurs de Shapley

Définition — Valeur de Shapley (théorie des jeux coopératifs)

Dans un jeu coopératif avec joueurs $\mathcal{N} = \{1, \dots, p\}$ et fonction caractéristique $v : 2^{\mathcal{N}} \rightarrow \mathbb{R}$, la valeur de Shapley du joueur j est :

$$\phi_j(v) = \sum_{S \subseteq \mathcal{N} \setminus \{j\}} \frac{|S|! (|\mathcal{N}| - |S| - 1)!}{|\mathcal{N}|!} [v(S \cup \{j\}) - v(S)]$$

Formule — SHAP — Adaptation au ML

On identifie chaque feature j à un joueur, et $v(S) = \mathbb{E}[f(\mathbf{x}) \mid \mathbf{x}_S]$ (prédiction en marginalisant sur les features absentes de S).

$$\phi_j(f, \mathbf{x}) = \sum_{S \subseteq \mathcal{N} \setminus \{j\}} \frac{|S|! (p - |S| - 1)!}{p!} [\mathbb{E}[f(\mathbf{x}) \mid \mathbf{x}_{S \cup \{j\}}] - \mathbb{E}[f(\mathbf{x}) \mid \mathbf{x}_S]]$$

Propriété additive (axiome d'efficacité) :

$$f(\mathbf{x}) = \phi_0 + \sum_{j=1}^p \phi_j(f, \mathbf{x})$$

où $\phi_0 = \mathbb{E}[f(\mathbf{x})]$ est la prédiction de base.

9.2. LIME

Formule — LIME — Approximation locale

Pour une instance $\mathbf{x}$, LIME résout :

$$g^* = \operatorname{argmin}_{g \in \mathcal{G}} \mathcal{L}(f, g, \pi_{\mathbf{x}}) + \Omega(g)$$

$$\mathcal{L}(f, g, \pi_{\mathbf{x}}) = \sum_{\mathbf{z}, \mathbf{z}' \in \mathcal{Z}} \pi_{\mathbf{x}}(\mathbf{z}) (f(\mathbf{z}) - g(\mathbf{z}'))^2$$

où $\pi_{\mathbf{x}}(\mathbf{z}) = \exp\left(-\frac{d(\mathbf{x}, \mathbf{z})^2}{2\sigma^2}\right)$ est une pondération exponentielle en distance, et $\Omega(g)$ est une pénalité de complexité.

9.3. Partial Dependence Plot (PDP)

Formule — PDP et ICE

L'effet marginal de la feature j (en marginalisant les autres) :

$$\hat{f}_j(x_j) = \mathbb{E}_{\mathbf{X}_{-j}} [\hat{f}(x_j, \mathbf{X}_{-j})] \approx \frac{1}{n} \sum_{i=1}^n \hat{f}(x_j, \mathbf{x}_{i,-j})$$

Les **courbes ICE** (Individual Conditional Expectation) montrent $\hat{f}(x_j, \mathbf{x}_{i,-j})$ pour chaque individu i séparément.

10. Clustering et Détection d'Anomalies

10.1. K-Means

Formule — Objectif K-Means

$$\min_{\{C_k\}, \{\mu_k\}} \sum_{k=1}^K \sum_{\mathbf{x} \in C_k} \|\mathbf{x} - \mu_k\|^2$$

L'algorithme de Lloyd alterne entre :

1. **Affectation** : $C_k^{(t)} = \{\mathbf{x}_i : k = \operatorname{argmax}_j \|\mathbf{x}_i - \mu_j^{(t)}\|^2\}$
2. **Mise à jour** : $\mu_k^{(t+1)} = \frac{1}{|C_k^{(t)}|} \sum_{\mathbf{x} \in C_k^{(t)}} \mathbf{x}$

Convergence garantie vers un optimum local. L'inertie est convexe par morceaux.

Formule — Score de silhouette

Pour chaque point $\mathbf{x}_i$ dans le cluster C_k :

$$a(i) = \frac{1}{|C_k| - 1} \sum_{j \in C_k, j \neq i} d(i, j) \quad (\text{cohésion intra-cluster})$$

$$b(i) = \min_{k' \neq k} \frac{1}{|C_{k'}|} \sum_{j \in C_{k'}} d(i, j) \quad (\text{séparation inter-cluster})$$

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \in [-1, 1]$$

10.2. Modèles de Mélange Gaussien (GMM)

Formule — GMM — Modèle génératif

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$

Estimé par l'algorithme **EM** (Expectation-Maximization) :

$$\text{E-step : } r_{ik} = \frac{\pi_k \mathcal{N}(\mathbf{x}_i; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_i; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}$$

$$\text{M-step : } \pi_k = \frac{N_k}{n}, \quad \boldsymbol{\mu}_k = \frac{\sum_i r_{ik} \mathbf{x}_i}{N_k}, \quad \boldsymbol{\Sigma}_k = \frac{\sum_i r_{ik} (\mathbf{x}_i - \boldsymbol{\mu}_k)(\mathbf{x}_i - \boldsymbol{\mu}_k)^\top}{N_k}$$

où $N_k = \sum_i r_{ik}$.

11. Séries Temporelles

11.1. Stationnarité et Test ADF

Définition — Stationnarité (au sens large)

Un processus $\{X_t\}$ est stationnaire (au sens large, ou WSS) si :

$$\mathbb{E}[X_t] = \mu \quad \forall t, \quad \text{Cov}(X_t, X_{t+h}) = \gamma(h) \quad \forall t$$

La fonction d'autocorrélation (ACF) est $\rho(h) = \gamma(h)/\gamma(0)$.

Formule — Test de Dickey-Fuller Augmenté (ADF)

Teste l'hypothèse nulle H_0 : présence d'une racine unitaire (non-stationnarité). Modèle :

$$\Delta X_t = \alpha + \beta t + \gamma X_{t-1} + \sum_{j=1}^p \delta_j \Delta X_{t-j} + \varepsilon_t$$

$H_0 : \gamma = 0$ (racine unitaire) vs $H_1 : \gamma < 0$ (stationnarité).

11.2. ARIMA

Formule — ARIMA(p, d, q)

X_t est un processus ARIMA si $\nabla^d X_t = (1 - B)^d X_t$ est un ARMA(p, q) :

$$\underbrace{\left(1 - \sum_{i=1}^p \phi_i B^i\right)}_{\text{partie AR}} (1 - B)^d X_t = \underbrace{\left(1 + \sum_{j=1}^q \theta_j B^j\right)}_{\text{partie MA}} \varepsilon_t$$

où B est l'opérateur retard ($BX_t = X_{t-1}$) et $\varepsilon_t \sim \text{BB}(0, \sigma^2)$.

SARIMA(p, d, q)(P, D, Q) $_s$ ajoute les termes saisonniers de période s :

$$\Phi_P(B^s) \phi_p(B) (1 - B^s)^D (1 - B)^d X_t = \Theta_Q(B^s) \theta_q(B) \varepsilon_t$$

11.3. Prophet (Modèle additif)

Formule — Modèle de Prophet

$$y(t) = g(t) + s(t) + h(t) + \varepsilon(t)$$

- $g(t)$: tendance (modèle logistique ou linéaire par morceaux avec points de changement)
- $s(t) = \sum_{n=1}^N \left[a_n \cos\left(\frac{2\pi nt}{P}\right) + b_n \sin\left(\frac{2\pi nt}{P}\right) \right]$: saisonnalité (série de Fourier)
- $h(t)$: effets des jours fériés
- $\varepsilon(t) \sim \mathcal{N}(0, \sigma^2)$: bruit résiduel

12. Traitement du Langage Naturel (NLP)

12.1. TF-IDF

Formule — TF-IDF

Pour un terme t dans un document d d'un corpus $\mathcal{C}$ de N documents :

$$\text{TF}(t, d) = \frac{\text{nb occurrences de } t \text{ dans } d}{\text{nb total de termes dans } d}$$

$$\text{IDF}(t, \mathcal{C}) = \log\left(\frac{N}{1 + |\{d \in \mathcal{C} : t \in d\}|}\right)$$

$$\text{TF-IDF}(t, d, \mathcal{C}) = \text{TF}(t, d) \times \text{IDF}(t, \mathcal{C})$$

12.2. Word2Vec

Formule — Skip-gram — Objectif

Pour chaque mot cible w_t et ses contextes w_{t+j} ($-c \leq j \leq c$) :

$$\mathcal{J} = -\frac{1}{T} \sum_{t=1}^T \sum_{-c \leq j \leq c, j \neq 0} \log P(w_{t+j} | w_t)$$

$$P(w_O | w_I) = \frac{\exp(\mathbf{v}_{w_O}^\top \mathbf{v}_{w_I})}{\sum_{w=1}^W \exp(\mathbf{v}_w^\top \mathbf{v}_{w_I})}$$

Les embeddings $\mathbf{v}_w \in \mathbb{R}^d$ capturent la sémantique distributionnelle : $\mathbf{v}_{\text{roi}} - \mathbf{v}_{\text{homme}} + \mathbf{v}_{\text{femme}} \approx \mathbf{v}_{\text{reine}}$.

13. Récapitulatif des Formules Clés

Méthode	Formule clé	Objectif
OLS	$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$	Minimiser MSE
Ridge	$(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}$	OLS + pénalité L2
LASSO	seuillage doux : $ \beta - \lambda/2$	Sélection sparse

Méthode	Formule clé	Objectif
Logistic Reg.	$P(y = 1) = \sigma(\beta^\top \mathbf{x})$	MLE, log-odds
SVM (dual)	$\max_{\alpha} \sum \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j k_{ij}$	Marge maximale
K-Means	$\min \sum_k \sum_{\mathbf{x} \in C_k} \ \mathbf{x} - \boldsymbol{\mu}_k\ ^2$	Inertie minimale
PCA	$\boldsymbol{\Sigma} \mathbf{v}_k = \lambda_k \mathbf{v}_k$	Variance max.
LDA	$\mathbf{S}_W^{-1} \mathbf{S}_B \mathbf{w} = \lambda \mathbf{w}$	Séparation classes
Adam	$\theta \leftarrow \theta - \frac{\eta}{\sqrt{\hat{v} + \epsilon}} \hat{m}$	Gradient adaptatif
LSTM	$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t$	Mémoire longue
SHAP	$\phi_j = \sum_S \frac{ S !(p- S -1)!}{p!} [v(S \cup j) - v(S)]$	Attribution marginale
GP prédiction	$\bar{\mathbf{f}}_* = \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I})^{-1} \mathbf{y}$	Régression bayésienne
TF-IDF	$\text{TF}(t, d) \times \log(N/df)$	Pondération lexicale
ARIMA	$\phi_p(B)(1-B)^d X_t = \theta_q(B) \varepsilon_t$	Modèle temporel
XGBoost	$\mathcal{J}^{(b)} \approx \sum_i [g_i f_b + \frac{1}{2} h_i f_b^2] + \Omega(f_b)$	Boosting 2nd ordre
BatchNorm	$\hat{x}_i = (x_i - \mu_B) / \sqrt{\sigma_B^2 + \epsilon}$	Stabilisation gradient
AUC-ROC	$\mathbb{P}(\hat{p}(x^+) > \hat{p}(x^-))$	Ranking probabiliste